

Sesgo de selección en estrategias de trading

Identificación de la sobrestimación del Sharpe Ratio en estrategias long-short sin data leakage

Juan Cruz Mendoza, Juan Ignacio Catania y Camila Rodríguez

Facultad de Ciencias Exactas y Naturales, Universidad de Buenos Aires · 2026

1. Introducción

Al desarrollar una estrategia en el mundo de las finanzas cuantitativas, es muy habitual probar muchas variantes de la misma idea y quedarse con la de mejor backtest. Aunque cada configuración se valide sin leakage, el máximo de muchas estimaciones ruidosas tiene un **sesgo de selección**, y la elegida suele rendir mucho peor out-of-sample.

Objetivo: mostrar lo fácil que es sobreajustar por este sesgo y evaluar si el DSR, la CSCV y un hold-out permiten detectarlo y medirlo.


2.1 Datos y estrategia

- Universo:** las 40 empresas más grandes del S&P 500 en 2005 que siguieron cotizando hasta 2025, con precios diarios.
- Features:** momentum 12-1, momentum 3 meses, reversión 1 mes, volatilidad 6 meses y tamaño (volumen en dólares de 12 meses).
- Target:** 1 si el retorno de la acción en los próximos h meses está en el cuantil superior del mes (tercil o quintil).
- Modelo base:** Random Forest de 200 árboles.
- Estrategia long-short:** cada h meses se compran las acciones con mayor probabilidad predicha y se hace un short con las de menor probabilidad, con pesos iguales.
- Costos:** 10bps por lado sobre el turnover de cada rebalanceo.
- Métrica:** Sharpe Ratio neto de costos, anualizado.

Dimensión	Valores	Opciones
Subconjunto de features	todas las combinaciones	31
Horizonte h	1, 3 y 6 meses	3
Cuantil del target	tercil, quintil	2
Profundidad máxima	2, 4 y 8	3
Mínimo de muestras por hoja	1 y 50	2
Configuraciones	$31 \times 3 \times 2 \times 3 \times 2$	1116

Se elige la configuración de mayor Sharpe Ratio en la validación cruzada (CV).

2.2 Validación sin leakage



- Purged K-fold ($K = 6$)** en el desarrollo: una serie out-of-sample de 144 meses por configuración.
- Purga:** sin muestras cuya etiqueta se solape con el test o con el hold-out.
- Embargo:** 12 meses después del test, porque las features miran 12 meses hacia atrás.
- Hold-out:** la elegida se evalúa una sola vez, al final (las 1116 también, solo para medir).

3.5 Resumen

	Sharpe Ratio CV (2006–2017)	Sharpe Ratio hold-out (2018–2025)	DSR (CV)
RF elegida por Sharpe Ratio	0.96	0.53	0.80
RF elegida por AUC	0.56	0.35	–
Promedio de las 1116 configuraciones	0.17	0.17	–

La elegida por AUC es la de mayor AUC de la CV (grupo $h = 6$, $q = 5$, el mismo de la elegida por Sharpe Ratio).

Referencias. Bailey, D. H. y López de Prado, M. (2014). The Deflated Sharpe Ratio: correcting for selection bias, backtest overfitting and non-normality. *The Journal of Portfolio Management*, 40(5), 94–107. Bailey, D. H., Borwein, J., López de Prado, M. y Zhu, Q. J. (2017). The probability of backtest overfitting. *Journal of Computational Finance*, 20(4), 39–69. López de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley.

Código: github.com/JuanCruzMendoza/quant-selection-bias

2.3 Deflated Sharpe Ratio (DSR)


Si las N configuraciones fueran independientes y ninguna tuviera señal, sus Sharpe Ratio serían aproximadamente normales, $\widehat{SR}_n \sim \mathcal{N}(0, \sigma^2)$, y su máximo seguiría aproximadamente una distribución de Gumbel. Su esperanza es el máximo esperado por azar:

$$SR_0 = \sigma \left[(1 - \gamma) \Phi^{-1} \left(1 - \frac{1}{N} \right) + \gamma \Phi^{-1} \left(1 - \frac{1}{Ne} \right) \right],$$

El DSR es la probabilidad de que el Sharpe Ratio verdadero de la elegida supere a SR_0 , corrigiendo por la asimetría, la curtosis y el largo de la serie. Como las configuraciones están correlacionadas ($\bar{\rho} = 0.58$), se usa el N efectivo $N_{ef} = \bar{\rho} + (1 - \bar{\rho}) N$, que da $SR_0 = 0.70$. La elegida es significativa si $DSR > 0.95$.


2.4 CSCV

La Combinatorially Symmetric Cross-Validation parte los 144 meses de retornos out-of-sample de las 1116 configuraciones en 12 bloques anuales:




En cada una de las formas de elegir 6 bloques in-sample (IS), se toma la configuración de mayor Sharpe Ratio IS (la campeona) y se mide su Sharpe Ratio en los otros 6 bloques (OOS). El promedio sobre las particiones es la **estimación CSCV**: estima lo que rinde out-of-sample el procedimiento de elegir la mejor.

3.1 La ventaja de la elegida no supera al máximo esperado por azar




Sharpe Ratio CV máximo entre n configuraciones sorteadas (promedio de 1000 sorteos). Se mide si la elegida supera en SR al resto.

3.2 En el hold-out, la elegida cae y el promedio no




La elegida cae de 0.96 a 0.53 y el promedio no se mueve: la caída se debe a la selección. La estimación CSCV (0.40) anticipó la caída.

3.3 La CV ordena, pero sobrestima a las mejores



Decil 1 es el 10 % más bajo, decil 10 es el 10 % más alto. En las puntas, los valores vuelven hacia el promedio: es regresión a la media, porque en los extremos pesa más el ruido.

3.4 Elegir por AUC no evita el problema



En cada grupo (h, q) se elige la mejor por Sharpe Ratio y la mejor por AUC de la CV: el gráfico muestra el promedio de los 6 grupos. Elegir por AUC evita el sesgo optimista, pero rinde menos.

4. Conclusiones

- Sobreajustar por selección es fácil.** Con purged K-fold, embargo y un hold-out intacto, el Sharpe Ratio de validación de la elegida (0.96) casi duplicó al del hold-out (0.53). Evitar el leakage no alcanza: el sesgo crece con la cantidad de intentos.
- Las herramientas lo detectan, si se registra todo.** El DSR y la estimación CSCV anticiparon la caída usando solo la data de desarrollo, pero necesitan conocer todos los intentos y sus retornos. Con una metodología rigurosa que guarda todas las corridas, podemos saber cuánto se “quemaron” los datos.
- Limitación:** survivorship bias. Las 40 acciones cotizaron durante todo 2005–2025, así que quedan afuera las empresas que quebraron o fueron adquiridas.