

Sesgo de selección en estrategias de trading

Identificación de la sobrestimación del Sharpe Ratio en estrategias long-short con Random Forest validadas sin data leakage

Juan Cruz Mendoza, Juan Ignacio Catania y Camila Rodríguez

Finanzas Cuantitativas · Facultad de Ciencias Exactas y Naturales, Universidad de Buenos Aires · 2026

1. Introducción

Al desarrollar una estrategia en el mundo de las finanzas cuantitativas, es muy habitual probar muchas variantes de la misma idea y quedarse con la de mejor backtest. Aún si cada configuración se valida sin leakage, el máximo de muchas estimaciones ruidosas tiene un sesgo optimista: es el **sesgo de selección**, y la estrategia elegida suele tener una performance mucho peor out-of-sample.

Objetivo: mostrar lo fácil que es sobreajustar por sesgo de selección, aún cuando se controlan todas las fuentes de data leakage, y evaluar si el DSR, la CSCV y un hold-out permiten detectarlo y medirlo.


2.1 Datos y estrategia

- Universo:** las 40 empresas más grandes del S&P 500 en 2005 (por volumen diario en dólares) que siguieron cotizando hasta 2025, con precios diarios de cierre ajustados por dividendos y splits de yfinance.
- Features:** momentum 12-1, momentum 3 meses, reversión 1 mes, volatilidad 6 meses y tamaño (volumen en dólares de 12 meses).
- Target:** 1 si el retorno de la acción en los próximos h meses está en el cuantil superior del mes (tercil o quintil).
- Modelo base:** Random Forest de 200 árboles.
- Estrategia long-short:** cada h meses se compran las acciones con mayor probabilidad predicha y se venden en corto las de menor probabilidad (13 u 8 por pata), con pesos iguales.
- Costos:** 10bps por lado sobre el turnover de cada rebalanceo.
- Métrica:** Sharpe Ratio neto de costos, anualizado.

Dimensión	Valores	Opciones
Subconjunto de features	todas las combinaciones	31
Horizonte h	1, 3 y 6 meses	3
Cuantil del target	tercil, quintil	2
Profundidad máxima	2, 4 y 8	3
Mínimo de muestras por hoja	1 y 50	2
Configuraciones	$31 \times 3 \times 2 \times 3 \times 2$	1116

Se elige la configuración de mayor Sharpe Ratio en la validación cruzada (CV).

2.2 Validación sin leakage



- Purged K-fold** en la data de desarrollo (enero 2006 – diciembre 2017), con $K = 6$ folds de 24 meses: cada mes se predice con el modelo del split en el que es test. Así se arma una serie out-of-sample de 144 meses por configuración.
- Purga:** se sacan del entrenamiento las muestras cuya etiqueta se solapa con el test (h meses antes) y las de 2017 cuya etiqueta mira 2018.
- Embargo:** 12 meses después del test, porque las features miran hasta 12 meses hacia atrás.
- Hold-out** (enero 2018 – diciembre 2025): la elegida se reentrena con todo el desarrollo y se evalúa una sola vez, al final. Las 1116 también se evalúan, solo para medir.

3.5 Resumen

	Sharpe Ratio CV (2006–2017)	Sharpe Ratio hold-out (2018–2025)	DSR (CV)
RF elegida por Sharpe Ratio	0.96	0.53	0.80
RF elegida por AUC	0.56	0.35	–
Promedio de las 1116 configuraciones	0.17	0.17	–

Sharpe Ratio anualizados y netos de costos. La elegida por AUC es la de mayor AUC de la CV (grupo $h = 6$, $q = 5$, el mismo de la elegida por Sharpe Ratio). El DSR solo está definido para la selección por Sharpe Ratio: 0.80 está debajo de 0.95, así que la elegida no es significativa.

Referencias, Bailey, D. H. y López de Prado, M. (2014). The Deflated Sharpe Ratio: correcting for selection bias, backtest overfitting and non-normality. *The Journal of Portfolio Management*, 40(5), 94–107. Bailey, D. H., Borwein, J., López de Prado, M. y Zhu, Q. J. (2017). The probability of backtest overfitting. *Journal of Computational Finance*, 20(4), 39–69. López de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley. Código: github.com/JuanCruzMendoza/quant-selection-bias

2.3 Deflated Sharpe Ratio (DSR)

Si las N configuraciones fueran independientes y ninguna tuviera señal, sus Sharpe Ratio estimados serían aproximadamente normales, $\widehat{SR}_n \sim \mathcal{N}(0, \sigma^2)$, y su máximo seguiría, para N grande, aproximadamente una distribución de Gumbel. Su esperanza es el máximo esperado por azar:

$$SR_0 = \sigma \left[\left(1 - \gamma\right) \Phi^{-1} \left(1 - \frac{1}{N}\right) + \gamma \Phi^{-1} \left(1 - \frac{1}{Ne}\right) \right],$$


donde $\gamma \approx 0.577$ es la constante de Euler-Mascheroni. El DSR es la probabilidad de que el Sharpe Ratio verdadero de la elegida supere a SR_0 :

$$DSR = \Phi \left(\frac{(\widehat{SR} - SR_0) \sqrt{T-1}}{\sqrt{1 - \hat{\gamma}_3 \widehat{SR} + \frac{\hat{\gamma}_4 - 1}{4} \widehat{SR}^2}} \right),$$

con la asimetría $\hat{\gamma}_3$ y la curtosis $\hat{\gamma}_4$ de los retornos y $T = 144$ meses. Como las configuraciones están correlacionadas ($\bar{\rho} = 0.58$), se usa el N efectivo $N_{ef} = \bar{\rho} + (1 - \bar{\rho})N = 464$, que da $SR_0 = 0.70$ anualizado. La elegida es significativa si $DSR > 0.95$.


2.4 CSCV

La Combinatorially Symmetric Cross-Validation parte los 144 meses de retornos fuera de muestra de las 1116 configuraciones en 12 bloques anuales:




En cada una de las $\binom{12}{6} = 924$ formas de elegir 6 bloques in-sample (IS), se toma la configuración de mayor Sharpe Ratio IS (la campeona) y se mide su Sharpe Ratio en los otros 6 bloques (OOS). El promedio sobre las 924 particiones es la **estimación CSCV**: estima lo que rinde fuera de muestra el procedimiento de elegir la mejor, no una configuración en particular. No reentrena modelos, así que no agrega leakage.

3.1 La ventaja de la elegida no supera al máximo esperado por azar




Para cada n se sortean 1000 subconjuntos de n configuraciones y se promedia su Sharpe Ratio CV máximo. La curva punteada es $\mu + SR_0(n)$, con la media ($\mu = 0.17$) y el desvío ($\sigma = 0.23$) de las 1116. Como suma la media, no mide si la elegida supera a cero, sino si supera al resto: la elegida (0.96) queda casi sobre la curva (0.93), así que su ventaja es la esperable por elegir el máximo de 1116 estimaciones ruidosas.

3.2 En el hold-out, la elegida cae y el promedio no




La elegida cae de 0.96 a 0.53, mientras que el promedio de las 1116 queda en 0.17: toda la caída se debe a la selección. La estimación CSCV (0.40), calculada solo con la data de desarrollo, anticipó el hold-out mucho mejor que la CV. Aún así, la elegida quedó en el puesto 112 de 1116: lo que se infló fue la estimación, no la elección.

3.3 Aún sobrestimando la performance, la CV puede hacer un ranking de las estrategias out-of-sample



Configuraciones agrupadas en deciles según su Sharpe Ratio de validación (1: el 10 % más bajo; 10: el 10 % más alto). La CV ordena, pero en las puntas los valores vuelven hacia el promedio: el decil superior cae de 0.60 a 0.44 y el inferior sube de -0.22 a -0.06 . Es regresión a la media: cuanto más extremo es un Sharpe Ratio en la CV, más pesa el ruido.

3.4 Elegir por AUC no evita el problema



En cada uno de los 6 grupos (h, q), que comparten el target, se elige la mejor configuración por Sharpe Ratio y por AUC de la CV. El gráfico muestra, para cada criterio, el promedio de las 6 elegidas. La elegida por AUC no tiene un sesgo optimista ($0.32 \rightarrow 0.31$), dado que no se eligió mirando el Sharpe Ratio, pero rinde menos: la elegida por Sharpe Ratio se infla ($0.75 \rightarrow 0.51$), pero la supera en el hold-out en 5 de los 6 grupos.

4. Conclusiones

- Sobreajustar por selección es fácil.** Con purged K-fold, embargo y un hold-out intacto, el Sharpe Ratio de validación de la elegida (0.96) casi duplicó al del hold-out (0.53). Evitar el leakage no alcanza: el sesgo crece con la cantidad de intentos.
- Las herramientas lo detectan, si se registra todo.** El DSR y la estimación CSCV anticiparon la caída usando solo la data de desarrollo, pero necesitan conocer todos los intentos y sus retornos. Con una metodología rigurosa, que fija el diseño de antemano, no lanza corridas sin un objetivo y guarda los resultados y las métricas de cada una, podemos saber cuánto se “quemaron” los datos.
- Limitación:** survivorship bias. Las 40 acciones cotizaron durante todo 2005–2025, así que quedan afuera las empresas que quebraron o fueron adquiridas.